33ª JORNADAS DE JÓVENES INVESTIGADORES · AUGM 2026

Desarrollo de un Prototipo de Procesamiento Local para la Detección, Clasificación y Análisis Predictivo de Manchas Solares mediante Visión Computacional e IA

Carlos Benítez
Universidad Nacional de Asunción · Facultad de Ingeniería
Ingeniería Mecatrónica

Coautores:
Dr. Juan Carlos Cabral · Dr. Diego Stalder
Dr. Christian E. Schaerer · Dr. José María Gómez
MSc. Jesús Núñez

1. Introducción y Objetivos
2. Fundamentos Teóricos
3. Diseño de Hardware
4. Diseño de Software
5. Resultados
6. Conclusiones

Introducción: Efectos del clima espacial

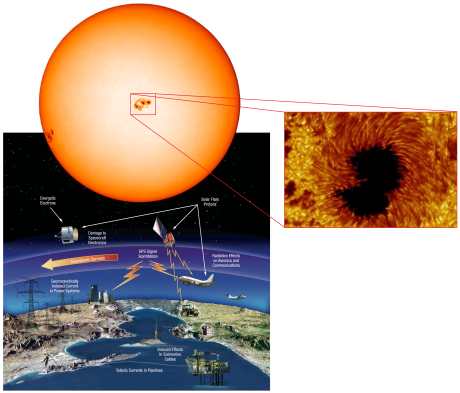

Sistemas vulnerables [1].

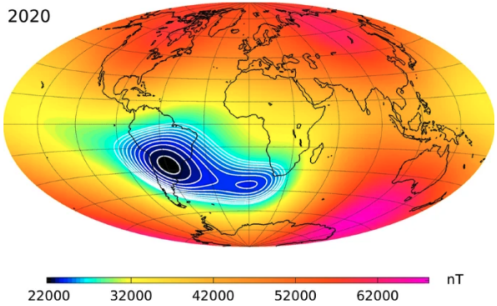

Anomalía magnética del Atlántico Sur [2].

[1] NASA Scientific Visualization Studio, "Solar Cycle Weather and Atmospheric Forcing Visualizations," NASA Goddard Space Flight Center, v4.12, 2010.
[2] C. C. Finlay, C. Kloss, N. Olsen, M. D. Hammer, A. Grayver, y A. Kuvshinov, "The CHAOS-7 geomagnetic field model and observed changes in the South Atlantic Anomaly," Earth, Planets and Space, vol. 72, art. no. 156, 2020.

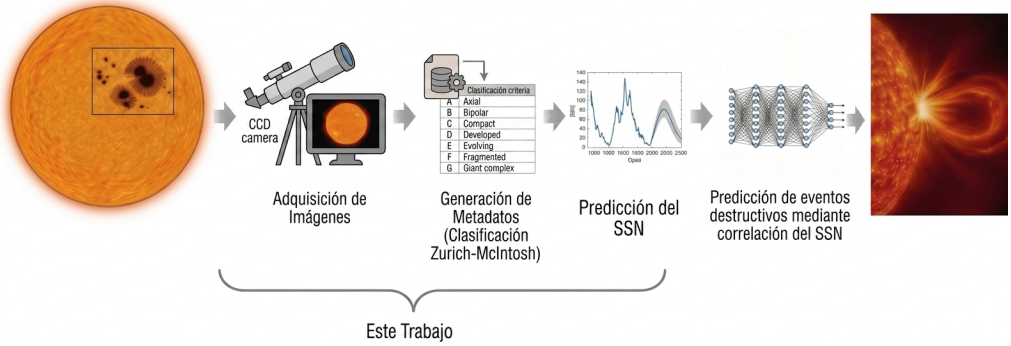

Flujo de trabajo de este proyecto.

Objetivo General

Desarrollar un prototipo para la detección y clasificación local de manchas solares, integrando técnicas de visión por computadora, inteligencia artificial y análisis predictivo de actividad solar para observatorios locales.

Objetivos Específicos

1. Analizar registros históricos de manchas solares a partir de imágenes heliográficas.
2. Diseñar un flujo de adquisición y preprocesamiento de imágenes para vincular observaciones locales con reportes internacionales.
3. Desarrollar un detector de grupos solares y un clasificador jerárquico de caracteres Zürich–McIntosh preservando dependencias semánticas.
4. Implementar un módulo predictivo de la evolución temporal y distribución latitudinal de manchas solares a partir de registros históricos.
5. Validar el funcionamiento integral del prototipo en entorno de observación.

Sistemas de Clasificación de Manchas solares

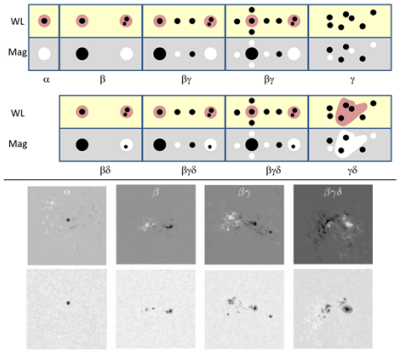

Clasificación de Wilson (8 clases) [3].

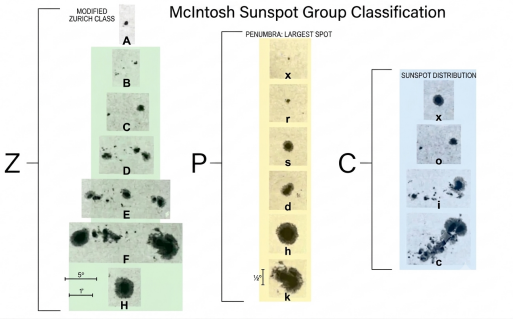

Clasificación de Zürich–McIntosh (60 clases) [3].

[3] P. S. McIntosh, "The classification of sunspot groups," Solar Physics, vol. 125, no. 2, pp. 251–267, 1990.

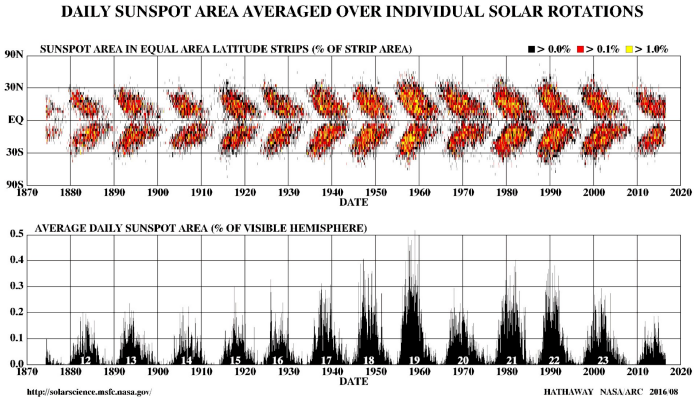

Diagrama de Spörer histórico [4].

[4] D. H. Hathaway, “The solar cycle,” Living Reviews in Solar Physics, vol. 12, no. 1, pp. 1–70, 2015.

Contribución 1

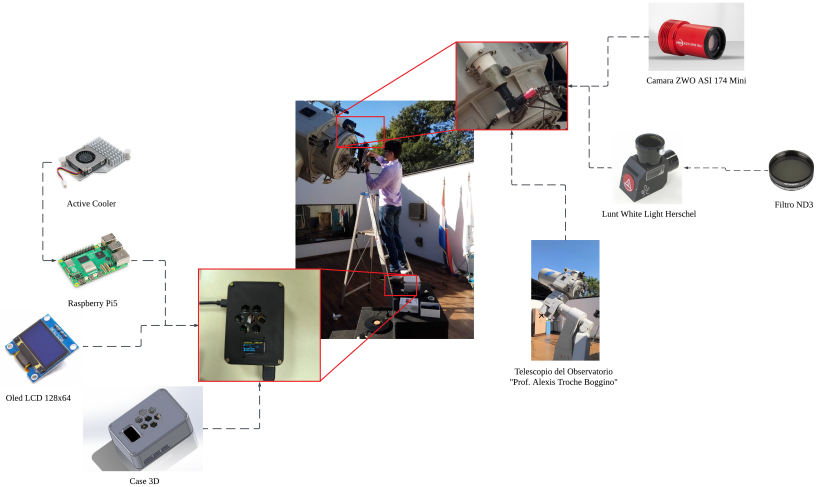

Diseño CAD e Integración de Hardware

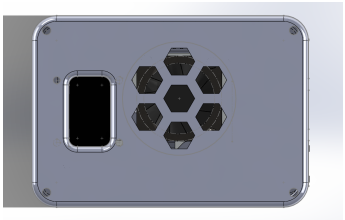

Carcasa exterior cerrada

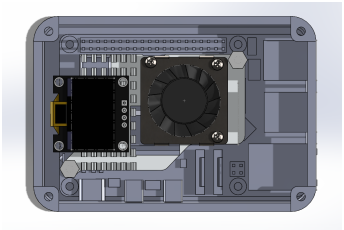

Disposición interna CAD

Prototipo físico fabricado

Modelado en SolidWorks y manufactura aditiva (impresión 3D PETG) del módulo de adquisición local y procesamiento embebido.

Datos de Entrenamiento: HMI/SDO + SRS/NOAA

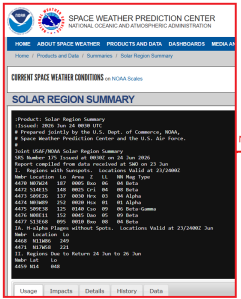

NOAA/SRS

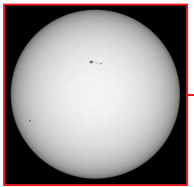

SDO/HMI

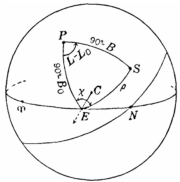

Conocidos B_0, ρ y θ, la latitud heliográfica B queda dada por

$$\sin(B) = \sin(B_0)\cos(\rho) + \cos(B_0)\sin(\rho)\cos(\theta),$$

mientras que la longitud heliográfica se recupera a partir de

$$L = \arcsin\big(\sin(\rho)\sin(\theta)\cos(B)\big) + L_0,$$

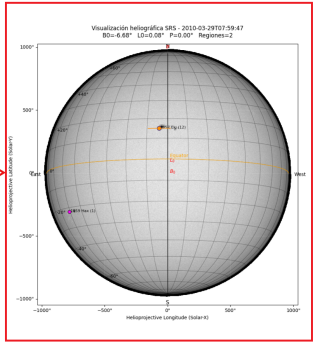

Datos de Entrenamiento: Discretización de Base de Datos

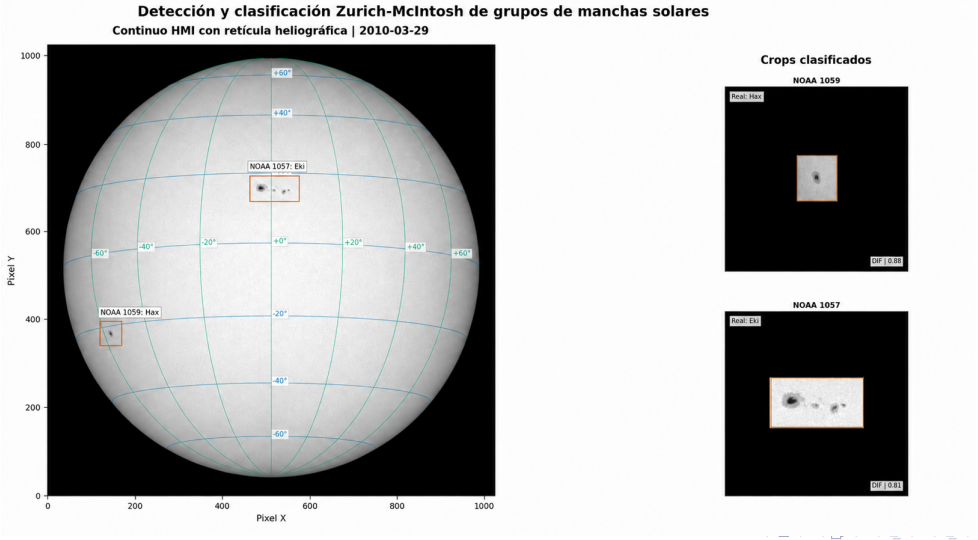

Datos de Entrenamiento: Datasets generados (2010–2025)

Contribución 2

DB1 – detección de grupos solares (Para YOLO26n)

- **4700 imágenes** de disco solar completo en **1024 × 1024 px**.
- Incluye *bounding boxes* de agrupamiento solar para entrenamiento tipo YOLO.

DB2 – clasificación morfológica (Etapa preliminar)

- **15000 recortes** derivados de los *bounding boxes* de DB1 de **224 × 224 px**.
- Incluye etiquetas *ZPC* de SRS/NOAA [5].

DB2.1 – clasificación morfológica refinada (Para ConvNeXtV2a)

- **14700 recortes** derivados de DB2 de **224 × 224 px** refinado con **PCA** de 60 componentes principales e Isolation Forest.
- Incluye etiquetas *ZPC* de SRS/NOAA [5].

[5] NOAA Space Weather Prediction Center, “Solar Region Summary (SRS) Data Logs,” 2025.

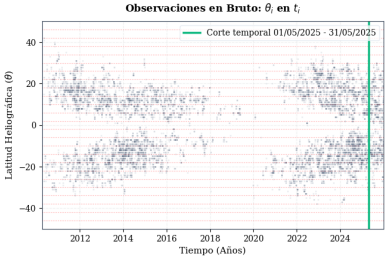

Criterio de Vectorización

1. Contenedores Latitudinales:
$B_j = [\theta_j, \theta_{j+1})$
$\theta \in [-50^\circ, 50^\circ]$, $\Delta\theta = 4^\circ$, $M = 25$

2. Proyección de Densidad:
$$V_j(t) = \sum_{i=1}^{N_{\text{manch}}(t)} \Psi_{j,i}(t)$$
$\Psi_{j,i}(t) = 1$ si $\theta_i(t) \in B_j$; 0 sino

3. Vector de Estado:
$\mathbf{x}_t = [V_1(t)\ \ V_2(t)\ \cdots\ V_M(t)]^T \in \mathbb{R}^M$

4. Matriz de Instantáneas:
$\mathbf{X} = [\mathbf{x}_1\ \ \mathbf{x}_2\ \cdots\ \mathbf{x}_N] \in \mathbb{R}^{M \times N}$

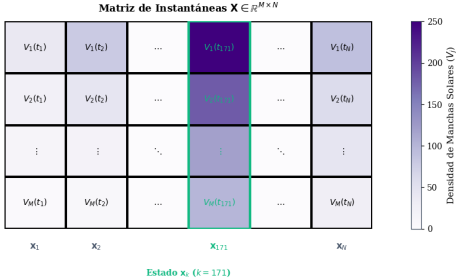

$$\mathbf{X} \in \mathbb{R}^{M \times N} \xrightarrow{\text{SVD}} \mathbf{U}_r \overset{\circ}{r} \mathbf{V}_r^T \implies \mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k, \quad \tilde{\mathbf{A}} = \mathbf{U}_r^T \mathbf{X}' \mathbf{V}_r \overset{\circ}{r}^{-1} \in \mathbb{R}^{r \times r}\ (r \ll M)\ [6].$$

[6] S. L. Brunton y J. N. Kutz, *Dynamic Mode Decomposition: Data-Driven Modeling of Complex Systems*, SIAM, 2016.

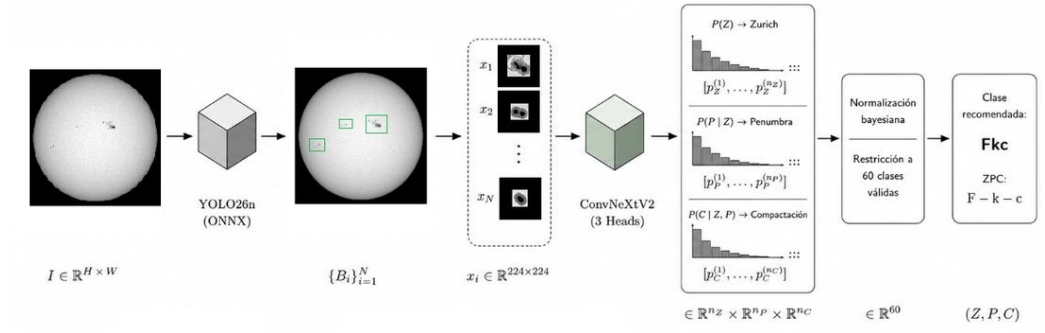

Pipeline jerárquico modular: Adquisición, detección con YOLO y clasificación morfológica con ConvNeXt.

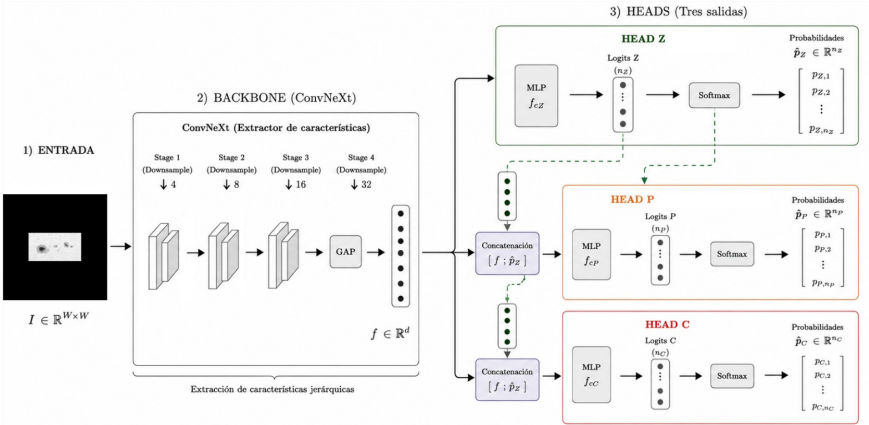

Arquitectura multietiqueta ConvNeXt con tres cabezales taxonómicos independientes (Z, P, C) y restricción bayesiana $P(Z, P, C \mid x) \propto P(Z \mid x)P(P \mid x)P(C \mid x)\,\mathcal{M}_{ZPC}$, donde $\mathcal{M}_{ZPC} \in \{0, 1\} \implies |\Omega_{\text{rec}}| = 60 \subset 168 = |\mathcal{Z} \times \mathcal{P} \times C|$.

Resultados: Modelos de Detección y Clasificación

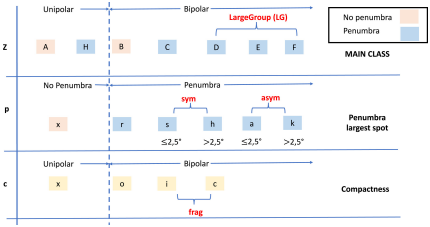

Compactación de clases en Sayez et al.

Autor	F1-Z	F1-P	F1-C	F1 p.
Palladino (2022) [7]	**0.67**	0.55	**0.72**	0.65
Sayez (2023) [8]	**0.68**	**0.65**	**0.72**	**0.68**
Deng (2025) [9]	0.47	0.41	0.60	0.49
Propuesta	**0.65**	**0.63**	**0.71**	**0.66**

Sayez et al. (2023) [8] agrupa las clases de algunos caracteres por lo que es de esperarse la mejoría en las métricas; sin embargo, este ajuste rompe la operatividad del modelo ya que introduce una clasificación distinta.

[7] L. Palladino, E. Ntagiou, J. Klug, J. Palacios, y R. Keil, "Sunspot groups detection and classification on SDO/HMI images using deep learning techniques," in 2022 IEEE Aerospace Conference. IEEE, 2022, pp. 1–10.
[8] M. Sayez et al., "SunSCC: Automated solar classification dataset," Astronomy & Astrophysics, 2023.
[9] X. Deng et al., "Deep learning-based McIntosh classification of sunspotgroups," Astronomy and Computing, vol. 53, p. 100995, 2025.

Resultados: Modelos Predictivos

Modelo vectorial: DMD-Spörer

Sunspot Number (DMD)

$$\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k$$

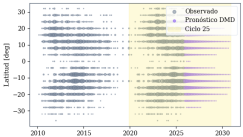

Reconstruccion de Spörer (DMD)

$$SSN_{DMD}(t) = \kappa \cdot \sum_{j=1}^{M} \hat{V}_j(t)$$

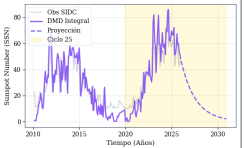

Modelo escalar: PVL + Kalman

Sunspot Number (PVL-Kalman)

$$SSN_{PVL}(v) = \frac{a \cdot v^3}{\exp(v^2/b^2) - 0.71}$$

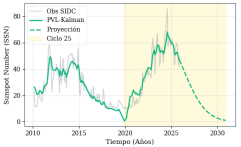

Modelo	MAE	RMSE	MAPE	R^2
PVLK [10]	15.31	22.02	33.27%	0.8173
DMD (Propuesta)	**15.22**	**20.30**	**32.54%**	**0.8449**

[10] T. Podladchikova y R. Van der Linden, "Kalman filter technique for improving prediction of smoothed monthly sunspot numbers," *Solar Physics*, vol. 271, no. 2, pp. 469–485, 2011.

Conclusiones

La articulación de los componentes de hardware y software permite extraer las siguientes conclusiones:

- **Autonomía:** El dispositivo de adquisición local permite el flujo de datos sin dependencia de conectividad externa constante.
- **Procesamiento en el borde (ONNX):** La integración de modelos basados en DMD y *Deep Learning* valida la viabilidad técnica de ejecutar tareas de clasificación y análisis predictivo en entornos locales.
- **Monitoreo:** El *framework* operativo unifica la captura y el análisis automatizado de forma desacoplada.

Identificador	Descripción de la Contribución	Vínculo
Contribución 1	Dispositivo de Adquisición local	OE_2, OE_5
Contribución 2	Base de datos etiquetada de actividad solar	OE_1, OE_2
Contribución 3	Modelo del Diagrama de Spörer basado en DMD	OE_4
Contribución 4	Modelo jerárquico de Deep Learning (Clasificación)	OE_3

¡Muchas Gracias!

Plataforma Web

Demostración interactiva y visualizador web.

`https://sunspot-page-app.vercel.app`

Repositorio del Proyecto

Código fuente, modelos ONNX y datasets.

`https://github.com/carlobeni/sunspot-page-app`