33ª JORNADAS DE JOVENS PESQUISADORES · AUGM 2026

Desenvolvimento de um Protótipo de Processamento Local para Detecção, Classificação e Análise Preditiva de Manchas Solares mediante Visão Computacional e IA

Carlos Benítez
Universidad Nacional de Asunción · Facultad de Ingeniería
Engenharia Mecatrônica

Coautores:
Dr. Juan Carlos Cabral · Dr. Diego Stalder
Dr. Christian E. Schaerer · Dr. José María Gómez
MSc. Jesús Núñez

1. Introdução e Objetivos
2. Fundamentação Teórica
3. Projeto de Hardware
4. Projeto de Software
5. Resultados
6. Conclusões

Introdução: Efeitos do clima espacial

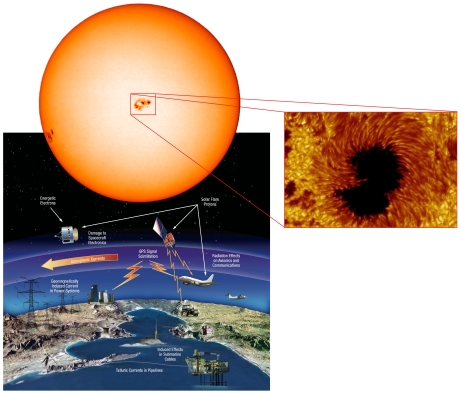

Sistemas vulneráveis [1].

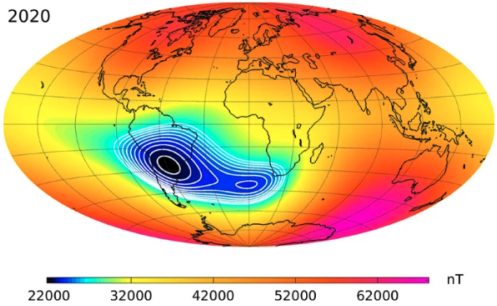

Anomalia magnética do Atlântico Sul [2].

[1] NASA Scientific Visualization Studio, “Solar Cycle Weather and Atmospheric Forcing Visualizations,” NASA Goddard Space Flight Center, v4.12, 2010.
[2] C. C. Finlay, C. Kloss, N. Olsen, M. D. Hammer, A. Grayver, y A. Kuvshinov, “The CHAOS-7 geomagnetic field model and observed changes in the South Atlantic Anomaly,” Earth, Planets and Space, vol. 72, art. no. 156, 2020.

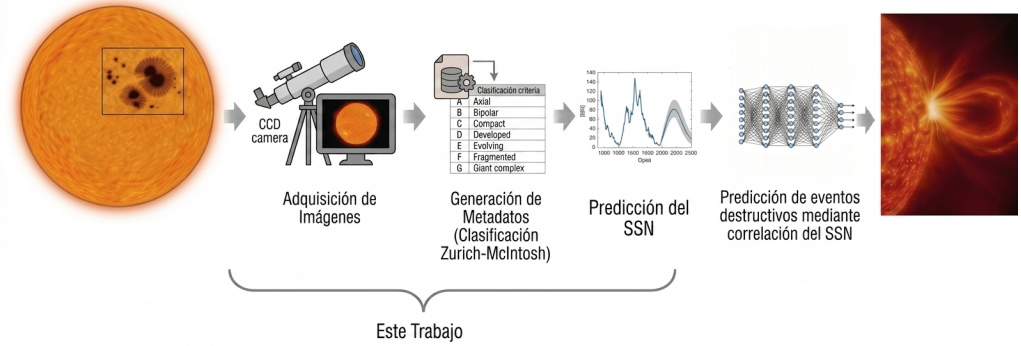

Fluxo de trabalho deste projeto.

Objetivos do Trabalho

Objetivo Geral

Desenvolver um protótipo para a detecção e classificação local de manchas solares, integrando técnicas de visão computacional, inteligência artificial e análise preditiva da atividade solar para observatórios locais.

Objetivos Específicos

1. Analisar registros históricos de manchas solares a partir de imagens heliográficas.
2. Projetar um fluxo de aquisição e pré-processamento de imagens para vincular observações locais a relatórios internacionais.
3. Desenvolver um detector de grupos solares e um classificador hierárquico de caracteres Zürich–McIntosh preservando dependências semânticas.
4. Implementar um módulo preditivo da evolução temporal e distribuição latitudinal de manchas solares a partir de registros históricos.
5. Validar o funcionamento integral do protótipo em ambiente de observação.

Sistemas de Classificação de Manchas Solares

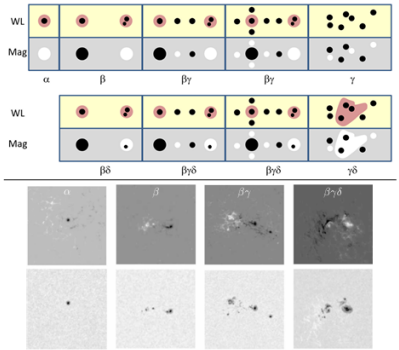

Classificação de Wilson (8 classes) [3].

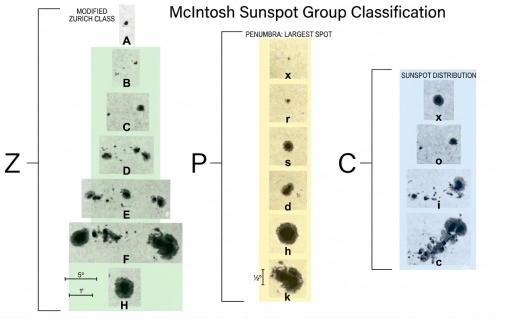

Classificação de Zürich–McIntosh (60 classes) [3].

[3] P. S. McIntosh, "The classification of sunspot groups," Solar Physics, vol. 125, no. 2, pp. 251–267, 1990.

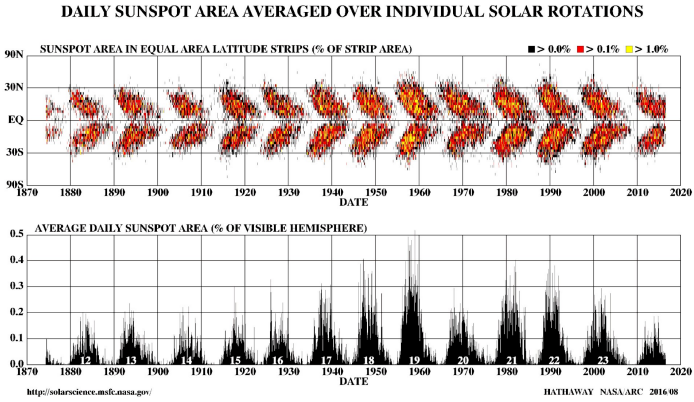

Diagrama de Spörer histórico [4].

[4] D. H. Hathaway, “The solar cycle,” Living Reviews in Solar Physics, vol. 12, no. 1, pp. 1–70, 2015.

Contribuição 1

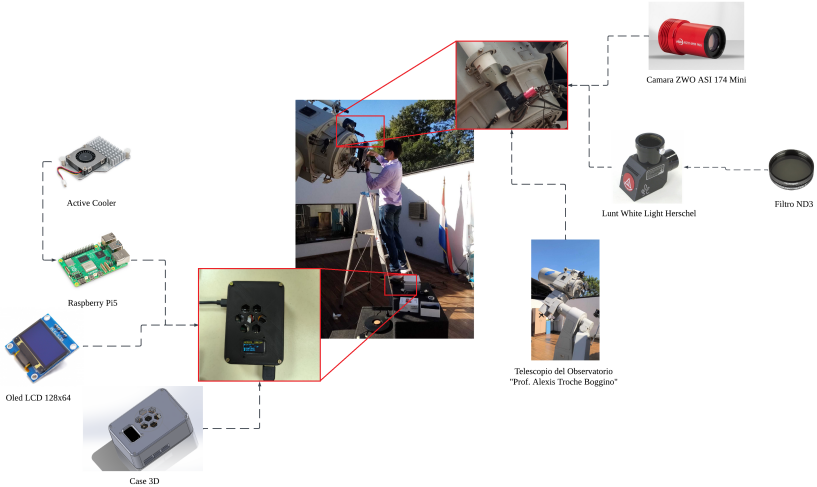

Projeto CAD e Integração de Hardware

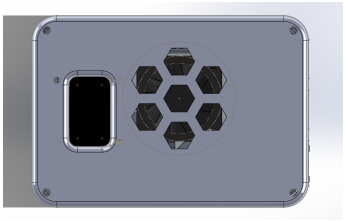

Gabinete externo fechado

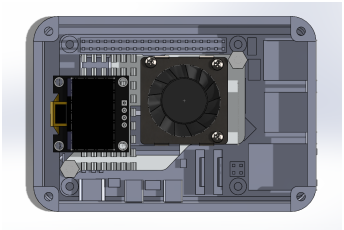

Disposição interna CAD

Protótipo físico fabricado

Modelagem no SolidWorks e manufatura aditiva (impressão 3D PETG) do módulo de aquisição local e processamento embarcado.

Dados de Treinamento: HMI/SDO + SRS/NOAA

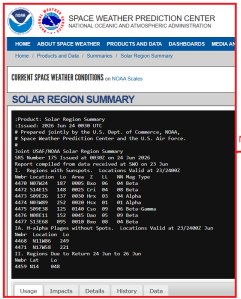

NOAA/SRS

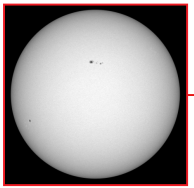

SDO/HMI

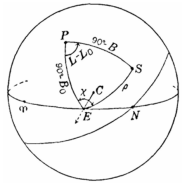

Conocidos B_0, ρ y θ, la latitud heliográfica B queda dada por

$$\sin(B) = \sin(B_0)\cos(\rho) + \cos(B_0)\sin(\rho)\cos(\theta),$$

mientras que la longitud heliográfica se recupera a partir de

$$L = \arcsin\big(\sin(\rho)\sin(\theta)\cos(B)\big) + L_0.$$

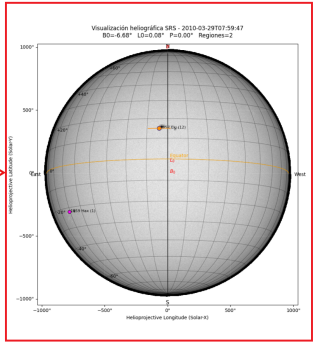

Dados de Treinamento: Discretização da Base de Dados

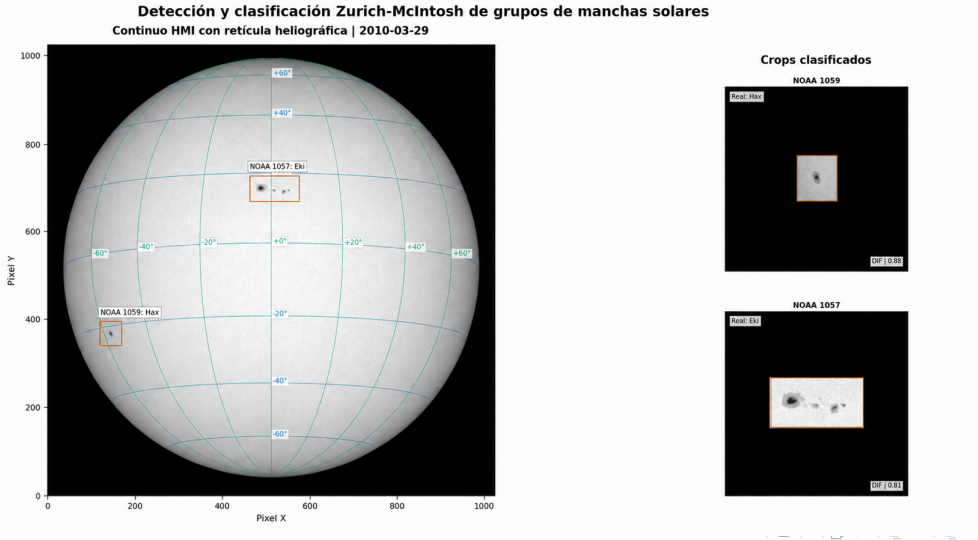

Dados de Treinamento: Datasets gerados (2010–2025)

Contribuição 2

DB1 – detecção de grupos solares (Para YOLO26n)

- **4700 imagens** de disco solar completo em $\mathbf{1024 \times 1024}$ **px**.
- Inclui *bounding boxes* de agrupamento solar para treinamento tipo YOLO.

DB2 – classificação morfológica (Etapa preliminar)

- **15000 recortes** derivados dos *bounding boxes* de DB1 em $\mathbf{224 \times 224}$ **px**.
- Inclui rótulos *ZPC* de SRS/NOAA [5].

DB2.1 – classificação morfológica refinada (Para ConvNeXtV2a)

- **14700 recortes** derivados de DB2 em $\mathbf{224 \times 224}$ **px** refinados com **PCA** de 60 componentes principais e Isolation Forest.
- Inclui rótulos *ZPC* de SRS/NOAA [5].

[5] NOAA Space Weather Prediction Center, “Solar Region Summary (SRS) Data Logs,” 2025.

Contribuição 3

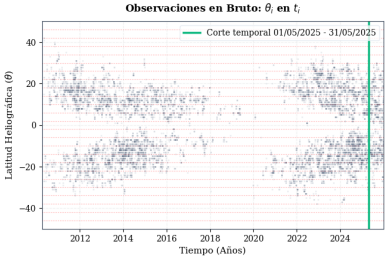

Criterio de Vectorización

1. Contenedores Latitudinales :
$\mathcal{B}_j = [\theta_j, \theta_{j+1})$
$\theta \in [-50^\circ, 50^\circ]$, $\Delta\theta = 4^\circ$, $M = 25$

2. Proyección de Densidad :
$V_i(t) = \sum_{j=1}^{N_{manc}(t)} \Psi_{j,i}(t)$
$\Psi_{j,i}(t) = 1$ si $\theta_i(t) \in \mathcal{B}_j$; 0 sino

3. Vector de Estado :
$\mathbf{x}_t = [V_1(t)\ \ V_2(t)\ \ \cdots\ \ V_M(t)]^T \in \mathbb{R}^M$

4. Matriz de Instantáneas :
$\mathbf{X} = [\mathbf{x}_1\ \ \mathbf{x}_2\ \ \cdots\ \ \mathbf{x}_N] \in \mathbb{R}^{M \times N}$

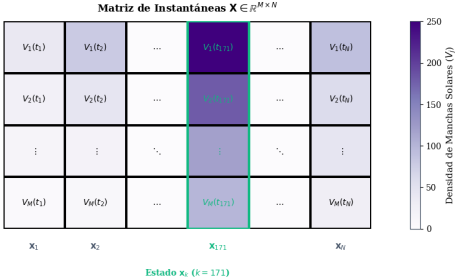

$$\mathbf{X} \in \mathbb{R}^{M \times N} \xrightarrow{\text{SVD}} \mathbf{U}_r \,^{\circ}{}_r \mathbf{V}_r^T \implies \mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k\,, \quad \tilde{\mathbf{A}} = \mathbf{U}_r^T \mathbf{X}' \mathbf{V}_r \,^{\circ}{}_r^{-1} \in \mathbb{R}^{r \times r}\ (r \ll M)\ [6].$$

[6] S. L. Brunton y J. N. Kutz, *Dynamic Mode Decomposition: Data-Driven Modeling of Complex Systems*, SIAM, 2016.

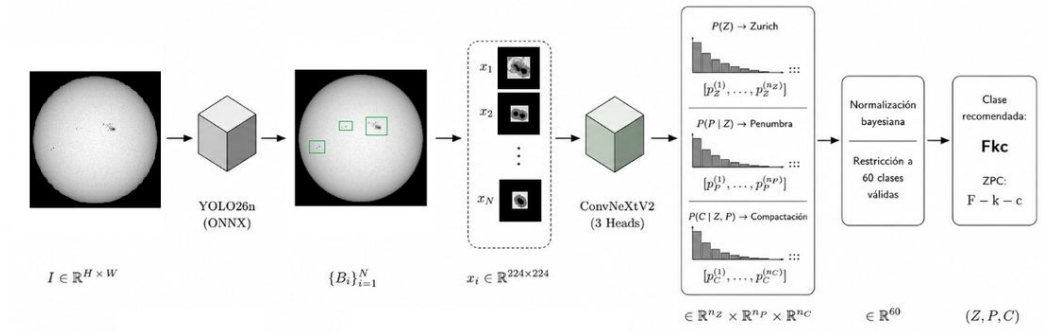

Pipeline hierárquico modular: Aquisição, detecção com YOLO e classificação morfológica com ConvNeXt.

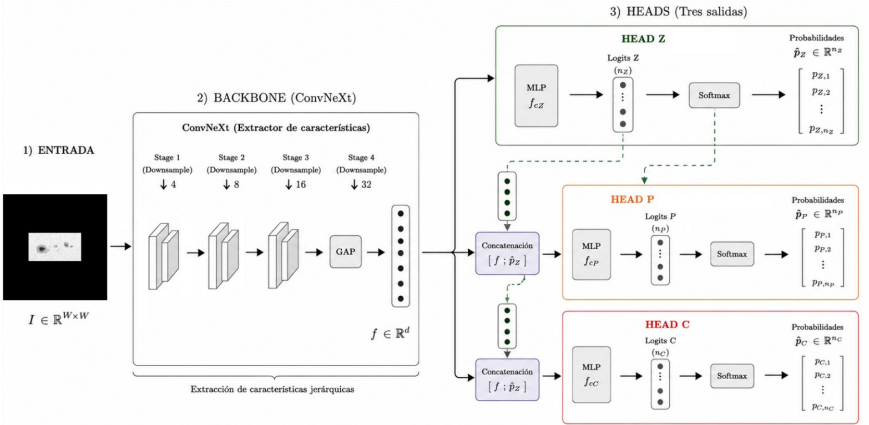

Arquitetura multirrótulo ConvNeXt com três cabeças taxonômicas independentes (Z, P, C) e restrição bayesiana $P(Z, P, C \mid x) \propto P(Z \mid x)P(P \mid x)P(C \mid x)\,\mathcal{M}_{ZPC}$, onde $\mathcal{M}_{ZPC} \in \{0, 1\} \implies |\Omega_{\text{rec}}| = 60 \subset 168 = |\mathcal{Z} \times \mathcal{P} \times C|$.

Resultados: Modelos de Detecção e Classificação

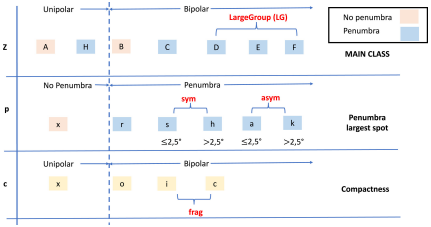

Compactação de classes em Sayez et al.

Autor	F1-Z	F1-P	F1-C	F1 p.
Palladino (2022) [7]	**0.67**	0.55	**0.72**	0.65
Sayez (2023) [8]	**0.68**	**0.65**	**0.72**	**0.68**
Deng (2025) [9]	0.47	0.41	0.60	0.49
Proposta	**0.65**	**0.63**	**0.71**	**0.66**

Sayez et al. (2023) [8] agrupa as classes de alguns caracteres, de modo que é esperada uma melhoria nas métricas; contudo, esse ajuste rompe a operacionalidade do modelo ao introduzir uma taxonomia distinta.

[7] L. Palladino, E. Ntagiou, J. Klug, J. Palacios, y R. Keil, "Sunspot groups detection and classification on SDO/HMI images using deep learning techniques," in 2022 IEEE Aerospace Conference. IEEE, 2022, pp. 1–10.
[8] M. Sayez et al., "SunSCC: Automated solar classification dataset," Astronomy & Astrophysics, 2023.
[9] X. Deng et al., "Deep learning-based McIntosh classification of sunspotgroups," Astronomy and Computing, vol. 53, p. 100995, 2025.

Resultados: Modelos Preditivos

Modelo vectorial: DMD-Spörer

Sunspot Number (DMD)

$$\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k$$

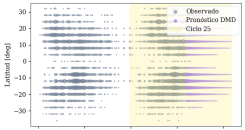

Reconstruccion de Spörer (DMD)

$$SSN_{DMD}(t) = \kappa \cdot \sum_{j=1}^{M} \hat{V}_j(t)$$

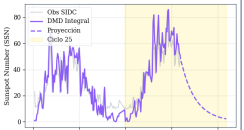

Modelo escalar: PVL + Kalman

Sunspot Number (PVL-Kalman)

$$SSN_{PVL}(v) = \frac{a \cdot v^3}{\exp(v^2/b^2) - 0.71}$$

Modelo	MAE	RMSE	MAPE	R^2
PVLK [10]	15.31	22.02	33.27%	0.8173
DMD (Proposta)	**15.22**	**20.30**	**32.54%**	**0.8449**

[10] T. Podladchikova y R. Van der Linden, "Kalman filter technique for improving prediction of smoothed monthly sunspot numbers," *Solar Physics*, vol. 271, no. 2, pp. 469–485, 2011.

Conclusões

A articulação dos componentes de hardware e software permite extrair as seguintes conclusões:

- **Autonomia:** O dispositivo de aquisição local viabiliza o fluxo de dados sem dependência de conectividade externa constante.
- **Processamento na borda (ONNX):** A integração de modelos baseados em DMD e *Deep Learning* valida a viabilidade técnica da execução de tarefas de classificação e análise preditiva em ambientes locais.
- **Monitoramento:** O *framework* operacional unifica a captura e a análise automatizada de forma desacoplada.

Identificador	Descrição da Contribuição	Vínculo
Contribuição 1	Dispositivo de aquisição local	OE_2, OE_5
Contribuição 2	Base de dados rotulada de atividade solar	OE_1, OE_2
Contribuição 3	Modelo do Diagrama de Spörer baseado em DMD	OE_4
Contribuição 4	Modelo hierárquico de Deep Learning (Classificação)	OE_3

Muito Obrigado!

Plataforma Web

Demonstração interativa e visualizador web.

`https://sunspot-page-app.vercel.app`

Repositório do Projeto

Código-fonte, modelos ONNX e datasets.

`https://github.com/carlobeni/sunspot-page-app`